

Laboratorio N° 3

Aprendizaje por Refuerzo: Métodos Basados en Modelo y Libres de Modelo

Asignatura: Inteligencia Artificial - Unidad N° 4: Aprendizaje por Refuerzo

Resolución de entornos de Gym mediante Value Iteration y Q-Learning

Fundamentación

El Aprendizaje por Refuerzo permite modelar problemas donde un agente aprende a tomar decisiones mediante interacción con un entorno. En este laboratorio se trabajará con dos enfoques principales:

- **Métodos basados en modelo**, donde se conoce o se estima la dinámica del entorno.
- **Métodos libres de modelo**, donde el agente aprende directamente a partir de la experiencia.

El entorno principal será **Frozen Lake**, disponible en la librería Gym/Gymnasium, evaluando tanto su versión determinística como estocástica.

Objetivos

Objetivo general

Implementar y comparar algoritmos clásicos de Aprendizaje por Refuerzo para resolver entornos discretos de decisión.

Objetivos específicos

- Comprender la diferencia entre entornos determinísticos y estocásticos.
- Implementar el algoritmo **Value Iteration**.
- Implementar el algoritmo **Q-Learning**.
- Comparar métodos basados en modelo y libres de modelo.
- Evaluar políticas obtenidas mediante métricas de desempeño.
- Aplicar los mismos algoritmos a un segundo entorno elegido de la librería Gym.

4. Contenidos involucrados

- Procesos de Decisión de Markov.

- Estados, acciones, recompensas y transiciones.
- Política óptima.
- Función de valor.
- Función Q.
- Value Iteration.
- Q-Learning.
- Exploración vs. explotación.
- Entornos determinísticos y estocásticos.

Punto 1: Resolución de Frozen Lake

Descripción del problema

Los alumnos deberán resolver el entorno **Frozen Lake** en sus dos modos:

a) Modo determinístico

```
env = gym.make("FrozenLake-v1", is_slippery=False)
```

b) Modo estocástico

```
env = gym.make("FrozenLake-v1", is_slippery=True)
```

El objetivo del agente es aprender una política que le permita llegar desde el estado inicial hasta la meta, evitando caer en los agujeros.

Parte A: Método basado en modelo

Implementar Value Iteration

Los alumnos deberán programar una función propia:

```
def value_iteration(env, gamma=0.99, theta=1e-8):
```

Implementa el algoritmo Value Iteration.

Parámetros:

env: entorno de Gym

gamma: factor de descuento

theta: criterio de convergencia

Retorna:

V: función de valor óptima

policy: política óptima

Se deberá:

1. Inicializar la función de valor.
2. Recorrer todos los estados.
3. Evaluar todas las acciones posibles.
4. Utilizar la dinámica del entorno env.P.
5. Actualizar los valores hasta convergencia.
6. Extraer la política óptima.
7. Ejecutar episodios de prueba usando la política obtenida.
8. Comparar los resultados en modo determinístico y estocástico.

Parte B: Método libre de modelo

Implementar Q-Learning

Los alumnos deberán programar una función propia:

```
def q_learning(env, episodes=10000, alpha=0.1, gamma=0.99, epsilon=1.0,
epsilon_decay=0.999):
```

Implementa el algoritmo Q-Learning.

Parámetros:

env: entorno de Gym

episodes: cantidad de episodios de entrenamiento

alpha: tasa de aprendizaje

gamma: factor de descuento

epsilon: probabilidad inicial de exploración

epsilon_decay: decaimiento de epsilon

Retorna:

Q: tabla Q aprendida

policy: política derivada de Q

rewards: recompensas por episodio

Se deberá:

1. Inicializar la tabla Q.
2. Aplicar una estrategia epsilon-greedy.
3. Actualizar Q mediante la ecuación de aprendizaje
4. Entrenar el agente en modo determinístico.
5. Entrenar el agente en modo estocástico.
6. Obtener la política final.
7. Evaluar el desempeño con episodios de prueba.
8. Comparar los resultados con Value Iteration.

Resultados esperados del Punto 1

Los alumnos deberán presentar:

- Tabla de valores obtenida con Value Iteration.
- Política óptima para Frozen Lake determinístico.
- Política óptima para Frozen Lake estocástico.

- Tabla Q final para ambos casos.
- Gráfica de recompensas durante el entrenamiento de Q-Learning.
- Comparación entre ambos métodos.
- Análisis de por qué el modo estocástico es más difícil.
- Conclusiones sobre estabilidad, convergencia y desempeño.

Punto 2: Resolución de otro entorno de Gym

Consigna

Cada grupo deberá elegir un segundo entorno discreto de la librería Gym/Gymnasium y resolverlo utilizando la misma metodología del Punto 1.

Requisitos

El entorno elegido debe permitir trabajar con:

- Espacio de estados discreto o continuo.
- Espacio de acciones discreto.
- Entrenamiento mediante Q-Learning.
- Análisis mediante política aprendida.

En caso de que el entorno posea dinámica accesible mediante env.P, también deberá resolverse mediante Value Iteration.

Actividades obligatorias

Para el entorno elegido, los alumnos deberán:

1. Describir el problema.
2. Identificar estados, acciones y recompensas.
3. Implementar Value Iteration, si el modelo está disponible.
4. Implementar Q-Learning.
5. Entrenar el agente.
6. Evaluar la política aprendida.

7. Graficar recompensas por episodio.
8. Comparar resultados.
9. Explicar dificultades encontradas.
10. Presentar conclusiones.

Entregables

Cada grupo deberá entregar:

1. Informe en PDF.
2. Código fuente en Python.
3. Gráficas obtenidas.
4. Tabla comparativa de resultados.
5. Conclusiones finales.

Estructura del informe

1. Portada.
2. Introducción.
3. Marco teórico.
4. Descripción de Frozen Lake.
5. Implementación de Value Iteration.
6. Implementación de Q-Learning.
7. Resultados para Frozen Lake determinístico.
8. Resultados para Frozen Lake estocástico.
9. Entorno elegido de Gym.
10. Resultados del segundo entorno.
11. Comparación general.
12. Conclusiones.
13. Bibliografía.